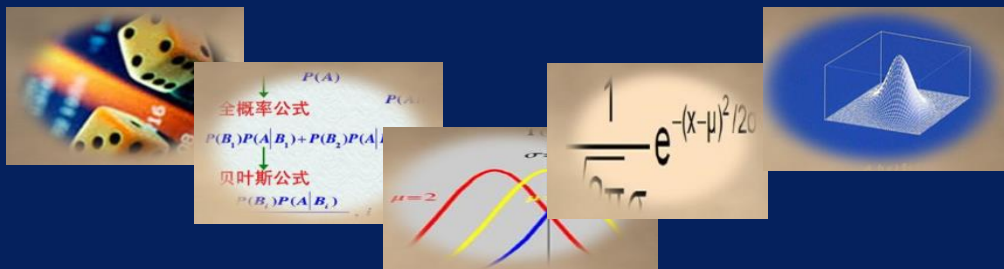
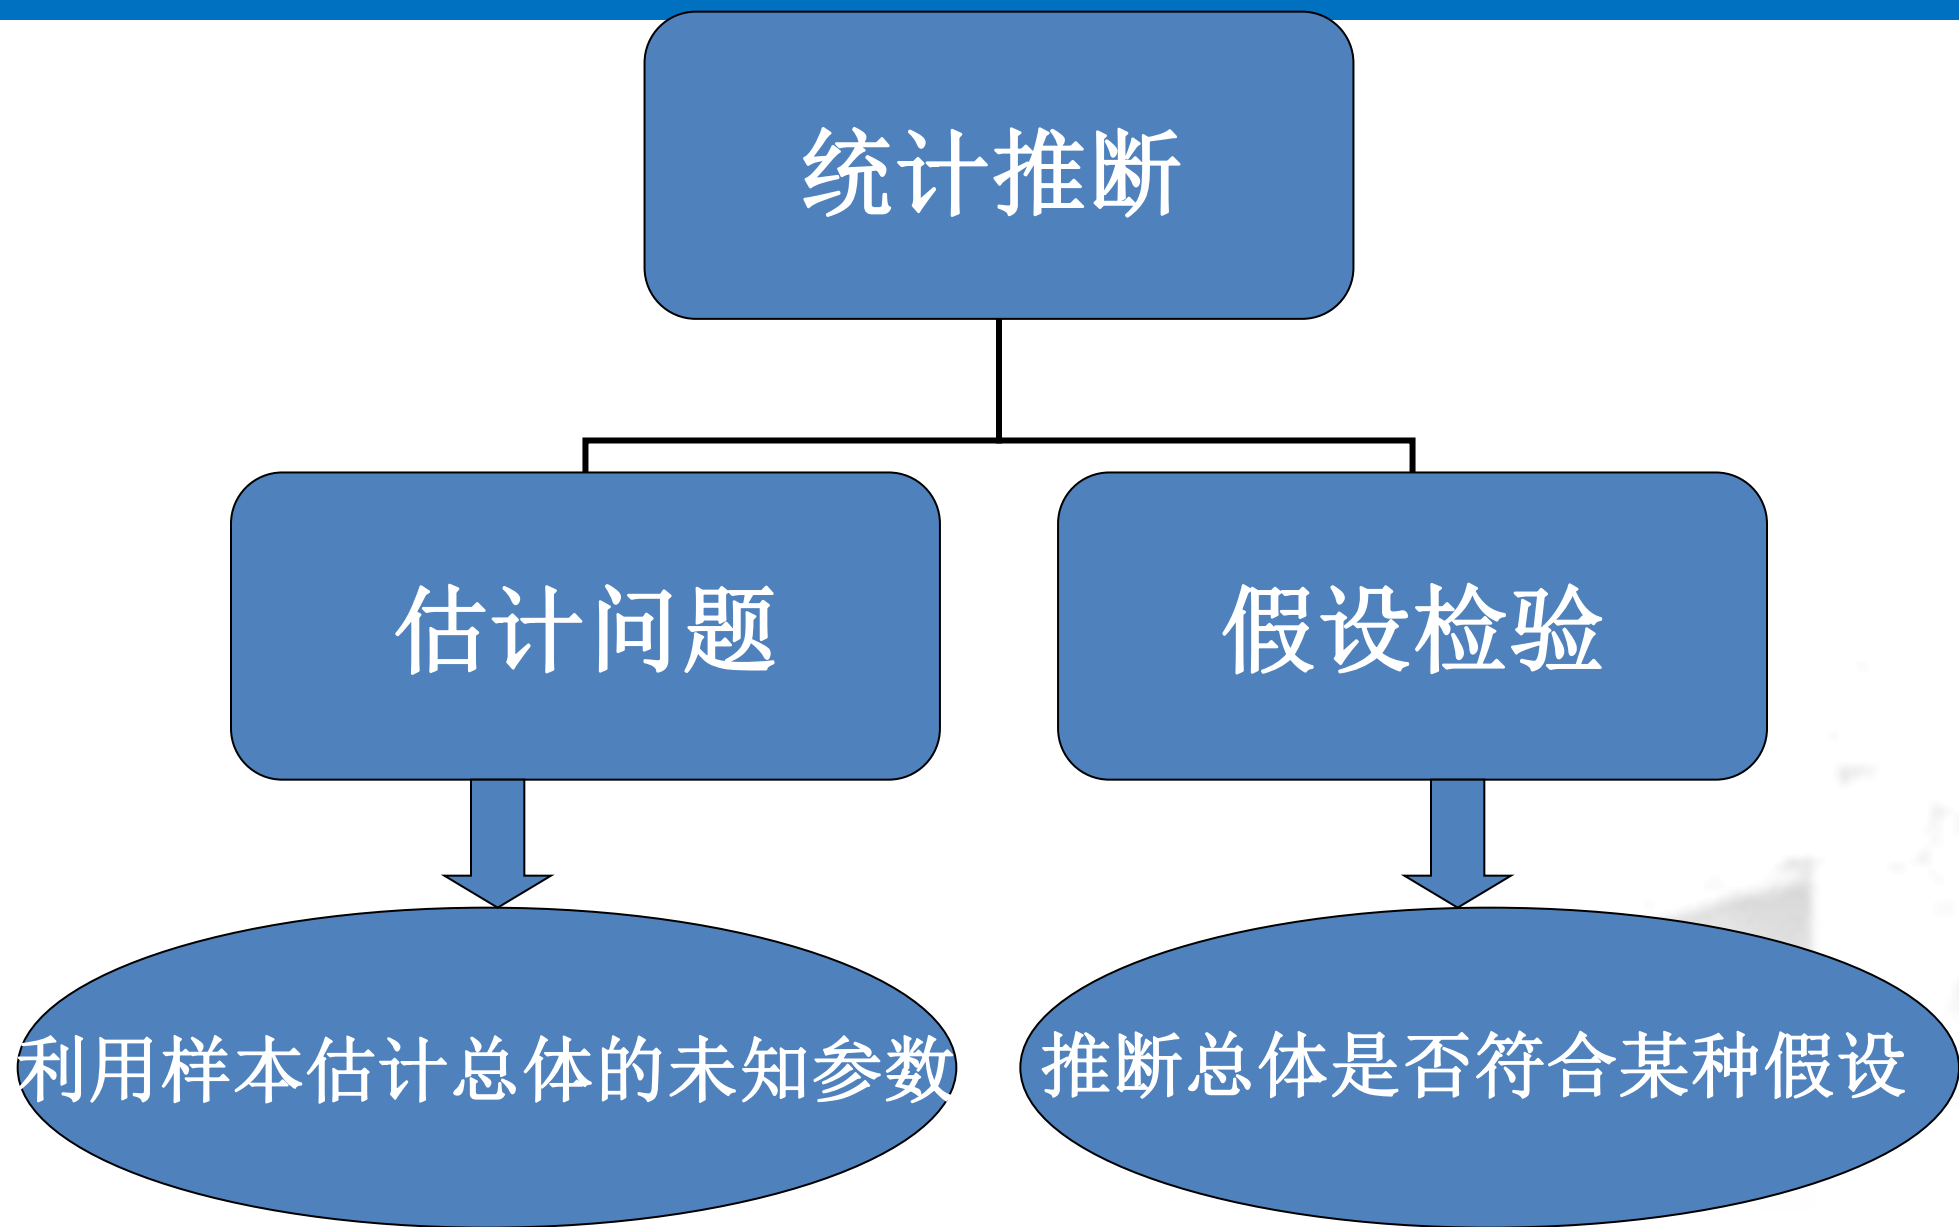


# 第七章 参数估计

## 7.1 点估计 (1) 矩估计法



杨建芳



# 参数估计

## 点估计

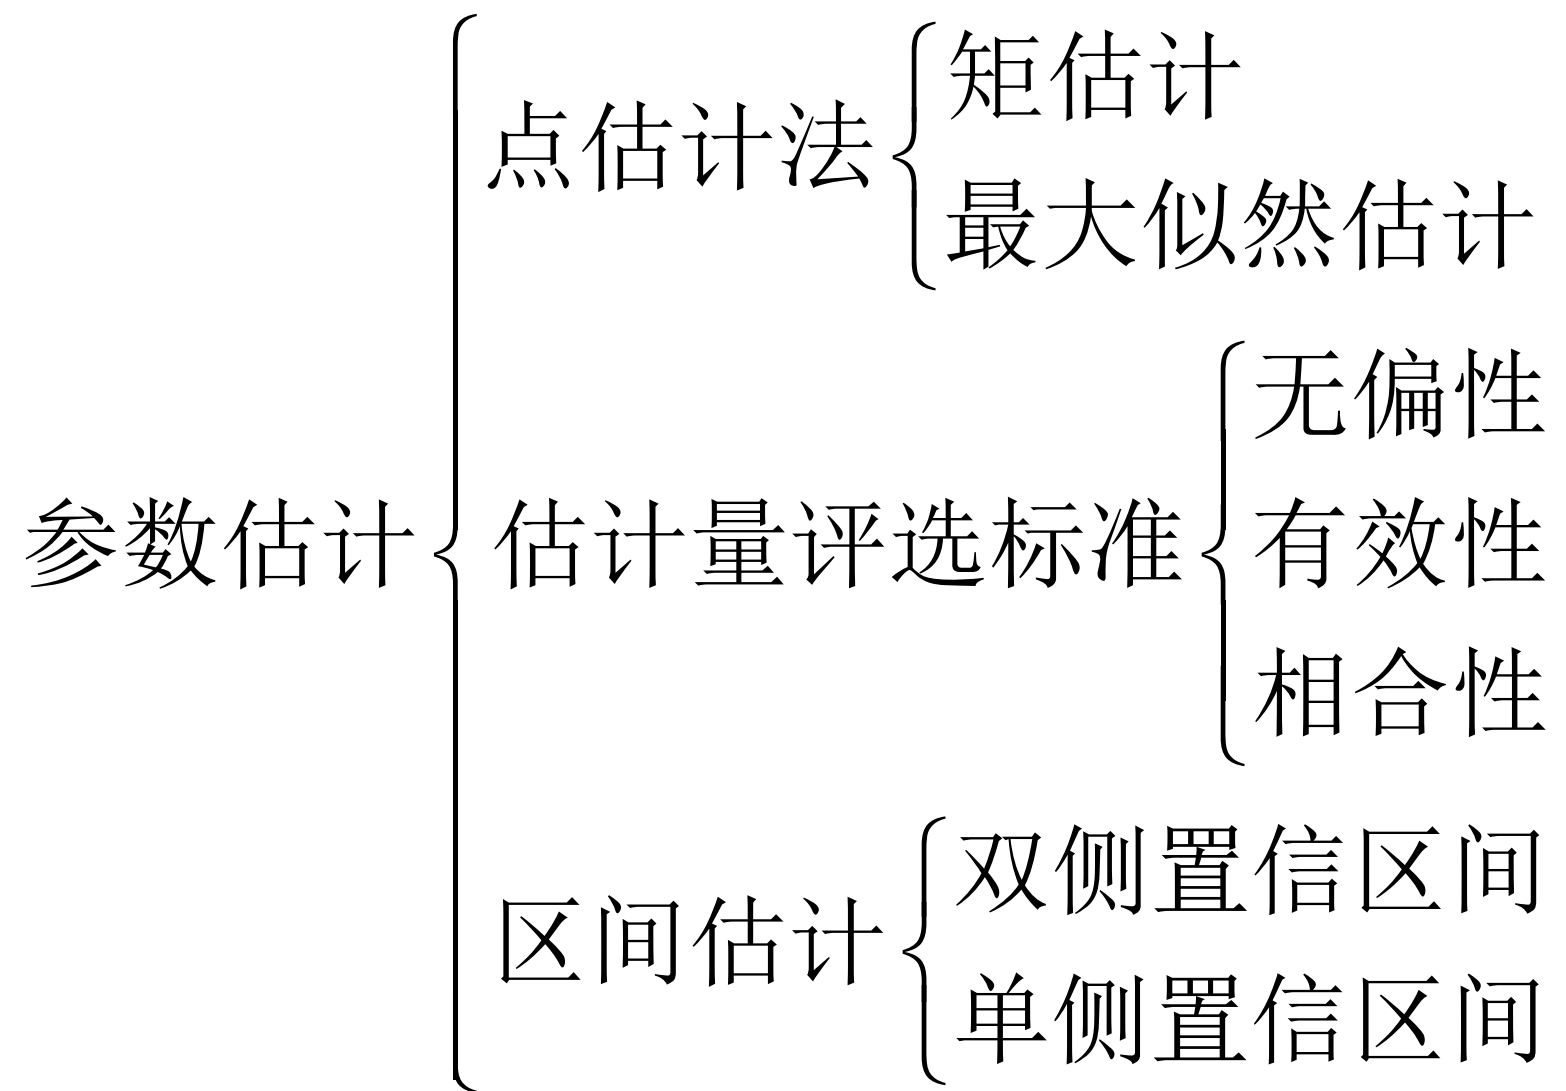
矩估计法

最大似然估计法

## 区间估计

双侧区间估计

单侧区间估计





# 参数的点估计 (Point Estimation)

设总体  $X$  的分布函数  $F(x; \theta)$  的形式已知，其中未知参数为  $\theta$ ，我们要构造样本  $(X_1, X_2, \dots, X_n)$  的一个适当的函数——即统计量  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ ，每当有了样本值  $(x_1, x_2, \dots, x_n)$ ，代入后得  $\hat{\theta}$  的一个值，作为未知参数  $\theta$  的估计值。为着这样的目的而构造的统计量  $\hat{\theta}$  称为 ( $\theta$  的) **估计量**。由于未知参数  $\theta$  是数轴上一个点，用  $\hat{\theta}$  去估计  $\theta$ ，等于用一个点去估计另一个点，所以这样的估计叫做 **点估计**。



# 矩估计法(The Method of Moments)

它是基于一种简单的“**替换**”思想建立起来的一种估计方法。

是英国统计学家**K. 皮尔逊**最早提出的。

其基本思想是**用样本原点矩估计总体原点矩**。

矩法估计的理论基础是：**辛钦大数定律**。





# 矩估计法(The Method of Moments)

记总体  $l$  阶矩为  $\mu_l = E(X^l)$

样本  $l$  阶矩为  $A_l = \frac{1}{n} \sum_{i=1}^n X_i^l$

大数定律:  $\bar{X} \xrightarrow{P} \mu, A_l \xrightarrow{P} \mu_l$

基本原理: 总体矩=样本矩, 令  $\mu_l = A_l$



# 矩估计法(The Method of Moments)

## 基本步骤:

步骤1: 求出总体原点矩  $u_l = E(X^l)$

(含有待估未知参数)

步骤2: 列方程或者方程组,

$$u_l = A_l, l = 1, 2, \dots, k$$

$k$ 为未知参数的个数

原点矩

步骤3: 解方程或者方程组, 求出矩估计

$$\hat{\theta}_l = \theta_l(A_1, A_2, \dots, A_k), l = 1, 2, \dots, k$$

注意:

选择原点矩;

几个未知参数选择几个矩;

从低阶到高阶选择矩。

只有一个未知参数时, 则令

$$E(X) = \bar{X}$$





**例1** 设总体  $X$  服从均匀分布  $U(0, \theta)$ ,  $(X_1, \dots, X_n)$  是取自  $X$  的样本, 求未知参数  $\theta$  的矩估计量。

**解** 步骤1 求出总体均值  $E(X) = \theta/2$ ,

步骤2 列方程

$$\text{令 } \frac{\theta}{2} = \bar{X}$$

步骤3 解方程

得  $\theta$  的矩估计量为  $\hat{\theta} = 2\bar{X}$ .

一个未知数,  
选择一个原点  
估计值  $\hat{\theta} = 2\bar{x}$ . 即均值

区别于真实值, 记得给估计量戴上帽子哦! 估计量实质是个随机变量



**例2** 设总体  $X$  服从正态分布  $N(\mu, \sigma^2)$ ,  $(X_1, \dots, X_n)$  是取自  $X$  的样本, 试求  $\mu, \sigma^2$  矩估计量。

**解** (1)  $E(X) = \mu; E(X^2) = \mu^2 + \sigma^2$

$$(2) \text{ 令 } \begin{cases} E(X) = \bar{X} = A_1; \\ E(X^2) = \frac{1}{n} \sum_{i=1}^n X_i^2 = A_2. \end{cases}$$

$$(3) \text{ 得 } \begin{cases} \hat{\mu} = \bar{X}; \\ \hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2. \end{cases}$$

两个未知数, 选择两个原点矩, 即一阶原点矩和二阶原点矩



## 练习题

1、设  $X \sim f(x; \theta) = \begin{cases} \theta c^\theta x^{-(\theta+1)}, & x > c, \\ 0, & x \leq c. \end{cases}$

其中  $c > 0$  为已知常数,  $\theta > 1$ ,  $\theta$  为未知常数,

求未知参数 ~~估计量~~ 估计量和估计值.

2、考虑泊松分布、指数分布等其他常见分布的矩估计量.

常见于选择填空题



## 练习1


**解** 步骤1 求出总体均值  $E(X) = \int_c^{+\infty} \theta c^\theta x^{-(\theta+1)} dx = \frac{c\theta}{\theta-1}$

步骤2 列方程  $\frac{c\theta}{\theta-1} = \bar{X}$

步骤3 解方程 估计量  $\hat{\theta} = \frac{\bar{X}}{\bar{X} - c}$

估计值  $\hat{\theta} = \frac{\bar{x}}{\bar{x} - c}$

思考



- 1、矩估计法的基本原理？解题步骤？
- 2、矩估计法采用的是什矩？
- 3、估计量和估计值的区别？



# 最大似然估计法（极大似然估计法） (The Method of Maximum Likelihood)

最大似然法, 也叫极大似然法, 它最早是由高斯所提出的, 后来由英国统计学家费歇(R · A · Fisher)于1912年在其一篇文章中重新提出, 并且证明了这个方法的一些性质. 极大似然估计这一名称也是费歇给的. 它是建立在极大似然原理的基础上的一个统计方法. 为了对极大似然原理有一个直观的认识, 我们先来看个例子.



# 最大似然估计法（极大似然估计法）

引例：设一个盒子中装有黑球、白球，两种球的数量之比为3:1，但不知哪种球多， $p$ 表示从盒子中任取一球是黑球的概率，那么 $p=1/4$ 或者 $p=3/4$ 。现在有放回的从盒中取3个球，试根据样本中的黑球数 $X$ 来估计参数 $p$ 。



## 最大似然估计法（极大似然估计法）

解：样本中黑球数  $X \sim b(3, p)$ ，即：

$$P\{X = x\} = C_3^x p^x (1-p)^{3-x} \quad (x = 0, 1, 2, 3)$$

对 $p$ 的两个可能值， $X$ 的分布律如下：

$X$	0	1	2	3
$p=1/4, P\{X=x\}$	27/64	27/64	9/64	1/64
$p=3/4, P\{X=x\}$	1/64	9/64	27/64	27/64

若 $X=0$ ， $p=1/4$   $P\{X=0\}=27/64 > P\{X=0\}=1/64$  ( $p=3/4$ )

根据这个样本可以推断 $p=1/4$ ，以此类推。





# 最大似然估计法（极大似然估计法）

极大似然估计法的基本思想：

根据样本值来选择参数，使该样本发生的概率最大。

离散型随机变量：

联合分布律

连续型随机变量：

联合密度函数

似然函数

如何体现样本发



# 最大似然估计法（极大似然估计法）

(1) 设总体为离散型随机变量，其分布律为未知参数， $(x_1, \dots, x_n)$

离散型随机变量的联合分布律

$$L(\theta) = \prod_{i=1}^n p(x_i; \theta) \text{ 为“似然函数”。}$$

是 $x_i$ ，不是 $x$

(注意：小写的 $x_i$ ， $x_i$ 代入的 $n$ 个分布律的连乘)

求 $\hat{\theta}$ ，使 $L(\theta)$ 达到最大，则称 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 $\theta$ 的**最大似然估计量**

求最大似然估计量实际上就是求似然函数最大值点问题。



# 最大似然估计法（极大似然估计法）

(2) 设总体为连续型，其概率密度函数为  $f(x; \theta)$ ，其中  $\theta$  为未知参数， $(x_1, \dots$

连续型随机变量的联合密度函数

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) \quad \text{为“似然函数”。}$$

是  $x_i$ ，不是  $x$

求  $\hat{\theta}$ ，使  $L(\theta)$  达到最大，则称  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的**最大似然估计量**

求最大似然估计量实际上就是求似然函数最大值点问题。



# 最大似然估计法（极大似然估计法）

求最大似然估计(MLE)的一般步骤是：

(1) 由总体分布导出样本的联合分布律（或

把样本联合概率分布律（或联合密度）中自变量看成已知常数，而把参数  $\theta$  看作自变量

似然函数  $L(\theta) = L(x_1, x_2, \dots, x_n; \theta)$

对数似然函数

(2) 求似然函数  $L(\theta)$  的最大值点（常常转化为求  $\ln L(\theta)$  的最大值点），即  $\theta$  的MLE：

$$\text{令 } \frac{d \ln(L(\theta))}{d \theta} = 0$$

一个未知参数：求导；

多个未知参数：求偏导。

(3) 解方程求出驻点，即为  $\theta$  的最大似然估计值  $\theta = \theta(x_1, x_2, \dots, x_n)$ ，

称  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的最大似然估计量。

# 最大似然估计法（极大似然估计法）

## 对数函数的基本性质：

若 $a > 0, b > 0$ , 则有：

$$(1) \ln ab = \ln a + \ln b$$

$$(2) \ln \frac{a}{b} = \ln a - \ln b$$

$$(3) \ln a^b = b \ln a$$

把似然函数转换成对数似然函数，  
不改变其最值点，但是可以简化  
计算，乘积转换成求和，商转换  
成差，乘方转换成乘积

思考



- 1、如何理解最大似然估计法的基本思想？
- 2、如何确定似然函数？
- 3、似然估计法的基本步骤？



# 第七章 参数估计

## 7.1 点估计 (3)

### 最大似然估计法的计算

杨建芳



# 最大似然估计法

求最大似然估计(MLE)的一般步骤是:

(1) 由总体分布导出样本的联合分布律 (或联合概率密度), 即:

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta)$$

(2) 求似然函数 $L(\theta)$ 的最大值点(常常转化为求 $\ln L(\theta)$ 的最大值点), 即 $\theta$ 的MLE:

$$\text{令 } \frac{d \ln(L(\theta))}{d\theta} = 0$$

(3) 解方程求出驻点, 即为 $\theta$ 的最大似然估计值 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ ,

称 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 $\theta$ 的最大似然估计量。





# 最大似然估计法的计算

例1 设总体 $X$ 服从指数分布，其密度函数为

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & , x \geq 0 \\ 0 & , x < 0 \end{cases},$$

$(X_1, \dots, X_n)$  是取自  $X$  的样本， $(x_1, x_2, \dots, x_n)$  为样本值，求未知参数  $\lambda$  极大似然估计量。



# 最大似然估计法的计算

解：(1) 似然函数： $L(\lambda) = \prod_{i=1}^n (\lambda e^{-\lambda x_i}) = \lambda^n e^{-\lambda \sum_{i=1}^n x_i}$

是 $x_i$ ，不是 $x$

(2) 取对数： $\ln L(\lambda) = n \ln \lambda - \lambda \sum_{i=1}^n x_i$ ，

取对数，简化计算

$$\text{令 } \frac{d \ln L(\lambda)}{d\lambda} = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0,$$

一个未知参数，求导，对于实际问题，唯一的驻点为最值

(3) 得： $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i}$  即  $\hat{\lambda} = \frac{1}{\bar{X}}$  为  $\lambda$  的极大似然估计量。

小写的为估计值，大写的为估计量。



## 最大似然估计法的计算

**例2** 设总体  $X \sim N(\mu, \sigma^2)$ ，样本  $(X_1, \dots, X_n)$ ，其中  $\mu$  和  $\sigma^2$  未知，试求  $\mu$  和  $\sigma^2$  的极大似然估计量。

**解：**(1) 似然函数  $L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$ ，

是  $x_i$ ，不是  $x$

(2) 取对数  $\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2$ ，

取对数，简化计算



# 最大似然估计法的计算


$$\text{令} \begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum (x_i - \mu) = 0 \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum (x_i - \mu)^2 = 0 \end{cases}$$

两个未知参数，求偏导，对于实际问题，唯一的驻点为最值点

$$(3) \text{ 解得} \begin{cases} \hat{\mu} = \frac{1}{n} \sum X_i = \bar{X}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2. \end{cases}$$

整理后，正态分布最大似然估计量与相应的矩估计量相同

即为  $\mu$  和  $\sigma^2$  的最大似然估计量。



如果似然函数不可导  
(或驻点不存在), 如  
何求最大值点?

利用高数中的知识即可!



## 最大似然估计法的计算

**例3 （了解）** 设总体  $X$  服从均匀分布  $U(0, \theta)$ ,  $(X_1, \dots, X_n)$  是取自  $X$  的样本, 求未知参数  $\theta$  的最大似然估计量。

**解**  $U(0, \theta)$  的密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} & , \quad 0 < x < \theta \\ 0 & , \quad \text{其它} \end{cases}$$



# 最大似然估计法的计算

似然函数为

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_1, \dots, x_n \leq \theta \\ 0, & \text{其它} \end{cases} = \begin{cases} \frac{1}{\theta^n}, & \theta \geq \max\{x_1, \dots, x_n\} \\ 0, & \text{其它} \end{cases}$$

显然驻点  
不存在

显然当  $\hat{\theta} = \max_{1 \leq i \leq n} x_i$  时,  $L$  最大,

故  $\theta$  的极大似然估计量为  $\hat{\theta} = \max_{1 \leq i \leq n} X_i$ .

比较:  $\theta$  的矩法估计量为  $\hat{\theta} = 2\bar{X}$ .



## 练习题

设总体  $X$  的概率密度为

$$f(x) = \begin{cases} (\theta + 1)x^\theta, & 0 < x < 1 \\ 0, & \text{else} \end{cases}$$

$(X_1, \dots, X_n)$  是取自  $X$  的样本,  $\theta > -1$  是未知参数, 试分别用矩估计法和最大似然估计法给出  $\theta$  的估计量。





# 练习题

## 解 矩估计法

(1) 总体 $X$ 的数学期望为

$$E(X) = \int_{-\infty}^{+\infty} xf(x) dx = \int_0^1 (\theta + 1)x^{\theta+1} dx = \frac{\theta + 1}{\theta + 2},$$

(2) 令  $\frac{\theta + 1}{\theta + 2} = \bar{X}$

(3) 得 $\theta$ 的矩估计量为  $\hat{\theta} = \frac{2\bar{X} - 1}{1 - \bar{X}}.$



## 最大似然估计法

$$(1) \quad L(\theta) = \begin{cases} (\theta + 1)^n \left( \prod_{i=1}^n x_i \right)^\theta, & 0 < x_i < 1 (i = 1, \dots, n) \\ 0, & \text{else} \end{cases}$$

$$(2) \quad \ln L = n \ln(\theta + 1) + \theta \sum_{i=1}^n \ln x_i, \quad \text{令} \frac{d \ln L}{d \theta} = \frac{n}{\theta + 1} + \sum_{i=1}^n \ln x_i = 0,$$

$$(3) \quad \text{解得} \theta \text{ 的最大似然估计值为: } \hat{\theta} = -1 - \frac{n}{\sum_{i=1}^n \ln x_i}.$$

$$\theta \text{ 的最大似然估计量为: } \hat{\theta} = -1 - \frac{n}{\sum_{i=1}^n \ln X_i}.$$

思考



- 1、如何通过求导或者偏导求最大似然估计值？
- 2、对于驻点不存在的似然函数如何求其最值点？



# 一、无偏性 (Unbiasedness)

估计量是随机变量，对于不同的样本值就会得到不同的估计值，希望估计值在未知参数真值左右徘徊，最好它的数学期望等于未知参数的真值，这就导致了无偏性这个标准。

**定义** 设  $(X_1, \dots, X_n)$  是总体  $X$  的一个样本， $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$  是未知参数  $\theta$  的估计量，如果有

$$E(\hat{\theta}) = \theta,$$

则称  $\hat{\theta}$  为  $\theta$  的**无偏估计量**。



# 一、无偏性 (Unbiasedness)

$$E(\hat{\theta}) = \theta$$

无偏估计量的含义是： $\hat{\theta}$  作为样本的函数是一个随机变量，它在  $\theta$  的真值附近波动，但其平均值恰好是  $\theta$  的真值。比如用一台秤去称物品，误差有两个来源：一是秤本身制作结构上的问题，这属于系统误差；另一种是操作上或其它随机因素的干扰，这属于随机误差。

无偏性即要求没有系统误差。



## 一、无偏性 (Unbiasedness)

设  $(X_1, \dots, X_n)$  为取自总体  $X$  的样本,

$$E(\bar{X}) = E(X),$$

说明  $\bar{X}$  是总体均值  $E(X)$  的无偏估计;

**样本方差**  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad E(S^2) = D(X),$

说明  $S^2$  是总体方差  $D(X)$  的无偏估计.



## 一、无偏性 (Unbiasedness)

**例1** 设总体  $X$  服从均匀分布  $U(0, \theta)$ , 试证  $\theta$  的矩法估计量  $\hat{\theta} = 2\bar{X}$  是  $\theta$  的无偏估计量。

**证** 
$$E(\hat{\theta}) = E(2\bar{X}) = 2E(\bar{X}) = 2E(X) = 2 \cdot \frac{\theta}{2} = \theta.$$

所以  $\hat{\theta}$  是  $\theta$  的无偏估计量。



## 一、无偏性 (Unbiasedness)

**例2** 设  $D(X) \neq 0$ ,  $E(\bar{X}) = \mu$ , 试问  $\bar{X}^2$  是否为  $\mu^2$  的无偏估计?

**证**

$$\begin{aligned} E(\bar{X}^2) &= D(\bar{X}) + [E(\bar{X})]^2 \\ &= \frac{1}{n} D(X) + \mu^2 \neq \mu^2, \end{aligned}$$

故  $\bar{X}^2$  不是  $\mu^2$  的无偏估计。





## 二、有效性 (Efficiency)

一般来说,一个参数往往有多个无偏估计量.

若  $\theta$  有两个无偏估计量:  $\hat{\theta}_1, \hat{\theta}_2$ , 则  $\hat{\theta} = a\hat{\theta}_1 + b\hat{\theta}_2$

当  $a+b=1$  时也是  $\theta$  的无偏估计量。

**定义** 设总体有一未知参数  $\theta$ , 样本  $(X_1, \dots, X_n)$ ,  $\hat{\theta}_1, \hat{\theta}_2$  均为  $\theta$  的无偏估计, 如果  $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ , 则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  **有效**。



## 二、有效性 (Efficiency)

**例3** 设  $(X_1, X_2, X_3)$  为取自总体  $X$  的样本, 试证明下列三个统计量均为  $E(X)$  的无偏估计量, 并比较有效性.

$$\hat{\theta}_1 = \frac{1}{5} X_1 + \frac{3}{10} X_2 + \frac{1}{2} X_3 ,$$

$$\hat{\theta}_2 = \frac{2}{3} X_1 + \frac{1}{2} X_2 - \frac{1}{6} X_3 ,$$

$$\hat{\theta}_3 = \frac{1}{3} X_1 + \frac{1}{3} X_2 + \frac{1}{3} X_3 .$$



$$\hat{\theta}_1 = \frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3, \hat{\theta}_2 = \frac{2}{3}X_1 + \frac{1}{2}X_2 - \frac{1}{6}X_3, \hat{\theta}_3 = \frac{1}{3}X_1 + \frac{1}{3}X_2 + \frac{1}{3}X_3.$$

证  $E(\hat{\theta}_1) = E\left(\frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3\right)$

$$= \left(\frac{1}{5} + \frac{3}{10} + \frac{1}{2}\right)E(X) = E(X),$$

$$E(\hat{\theta}_2) = \left(\frac{2}{3} + \frac{1}{2} - \frac{1}{6}\right)E(X) = E(X),$$

$$E(\hat{\theta}_3) = \left(\frac{1}{3} + \frac{1}{3} + \frac{1}{3}\right)E(X) = E(X),$$

所以  $\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3$   
均为  $E(X)$  的无偏  
估计量。



$$\hat{\theta}_1 = \frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3, \hat{\theta}_2 = \frac{2}{3}X_1 + \frac{1}{2}X_2 - \frac{1}{6}X_3, \hat{\theta}_3 = \frac{1}{3}X_1 + \frac{1}{3}X_2 + \frac{1}{3}X_3.$$

证  $D(\hat{\theta}_1) = D(\frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3)$

$$= (\frac{1}{25} + \frac{9}{100} + \frac{1}{4})D(X) = 0.38D(X),$$

$$D(\hat{\theta}_2) = (\frac{4}{9} + \frac{1}{4} + \frac{1}{36})D(X) = 0.72D(X),$$

$$D(\hat{\theta}_3) = (\frac{1}{9} + \frac{1}{9} + \frac{1}{9})D(X) = 0.33D(X).$$

所以  $\hat{\theta}_3$  最为有效。



### 三、一致性 (Consistency) (不要求)

**定义** 如果对  $\forall \varepsilon > 0$ , 有  $\lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| \geq \varepsilon\} = 0$ ,

称  $\hat{\theta}_n$  是  $\theta$  的**一致估计量**或**相合估计量**。

即当  $n \rightarrow \infty$  时,  $\hat{\theta}(X_1, X_2, \dots, X_n)$  依概率收敛于  $\theta$ 。

直观上看, 当  $n$  增大时, 样本信息增多, 当然希望估计量越来越靠近真值的概率也越来越大, 这种想法就引出了上面的一致性概念。一致估计量一般地是当样本容量很大时, 才能显示其优点。

**大数定律:**  $X \xrightarrow{P} \mu, A_l \xrightarrow{P} \mu_l$

可知样本原点矩  $X$  和  $A_l$  分别是  $E(X)$  和  $\mu_l$  的一致估计量。



# 估计量的评选标准

一、无偏性

$$E(\hat{\theta}) = \theta$$

二、有效性

$$D(\hat{\theta}_1) < D(\hat{\theta}_2)$$

三、一致性

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P} \theta$$



如何理解无偏性、有效性、一致性？



谢谢大家!

